

# Engenharia de Dados: MVP

Este é um documento de texto para o MVP para a sprint de Engenharia de Dados da pós-graduação de Ciência de Dados & Analytics da PUC-Rio 2026. O trabalho prevê a construção de um Pipeline de Dados na Nuvem.

O MVP foi desenvolvido utilizando o Databricks Free Edition – versão básica e gratuita do Databricks – para realizar uma análise da indústria internacional de produção de filmes.

## Ficha do Projeto

**Nome:** Ana Rachel Avelino Freire Faria

**Matrícula:** 4052026000594

**Data:** 27/09/2016

**Dataset I:** Full TMDB Movies Dataset 2024 (1M Movies) (TMDB\_movie\_dataset\_v11.csv)

**Disponível em:**

<https://www.kaggle.com/datasets/asaniczka/tmdb-movies-dataset-2023-930k-movies>

**Dataset II:** TMDB 5000 Movie Dataset (tmdb\_5000\_credits.csv)

**Disponível em:**

<https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata>

## Menu

I. Definição da Questão e Objetivo ↓

II. Busca de Dados e Definição do Dataset ↓

III. Modelagem ↓

IV. Carga (ETL) ↓

V. Análise ↓

VI. Autoavaliação ↓

## I. Definição da Questão e Objetivo

O cenário internacional de produção de filmes é bastante rico. Não somente há grandes produções como também aos poucos, em especial com o advento das plataformas de streaming temos cada vez mais contato com obras de diferentes continentes e culturas. Nesse contexto se faz interessante e até fundamental para a indústria cultural ter informações mais ricas e bem trabalhadas, tanto de um ponto de vista de negócios e risco, quanto por uma visão de sociedade.

A intenção deste mvp é montar uma pipeline com dados de filmes internacionais, com o objetivo de possibilitar a exploração das informações disponíveis e sua utilização para adquirir *insights* sobre o tema.

Algumas muitas questões levantadas inicialmente:

1. Qual a proporção de filmes por gênero temático?
2. Qual a Era Histórica mais lucrativa?
3. Quais os filmes mais bem quistos pelo público?
4. Quais os mais bem sucedidos?
5. Quais os filmes menos bem sucedidos?
6. Quem são os atores mais prolíferos?
7. Quem tem os filmes mais populares?
8. Renda média dos atores?
  - 8.1. Percentual do valor total do mercado pertence aos mais bem pagos?
9. Quem são os diretores mais prolíferos?
10. Em que idade começam e param de atuar?
  - 10.1. Qual a idade média dos atores?
  - 10.2. Atores de um mesmo elenco costumam ter muita diferença de experiência?
11. Quem são os escritores dos filmes de melhor nota?
  - 11.1. Quantos filmes os escritores mais populares já escreveram?
12. Qual a relevância dos filmes de animação?
  - 12.1. Datas dos primeiros filmes?
  - 12.2. Progressão?

## II. Busca de Dados e Definição do Dataset

Diversas opções de datasets e APIs foram analisados durante a busca de dados para coleta. Considerando os objetivos do projeto, foram priorizados dados de fontes que oferecessem diversidade de tempo e origem e um volume mínimo, principalmente para

dados financeiros – que costumam ser estimados, não sendo divulgados em totalidade – e de gênero.

Durante essa busca inicial, já pude perceber que seria muito difícil responder perguntas mais ligadas ao financeiro e mesmo idade de atores e equipe de produção. Apesar de haver várias opções de dados facilmente disponíveis, no geral esse tipo de informação não é registrada formalmente mesmo quando mencionada. Seria necessário um esforço grande de compilação de dados não estruturados espalhados pela internet – e que muito provavelmente não valeriam o investimento, considerando o volume plausível de ser encontrado.

Para realizar essa exploração e análise foram selecionados dois datasets sobre filmes. Ambos os datasets estão disponíveis na plataforma kaggle e foram compilados a partir de extrações feitas do site TMDb, a partir de sua API própria.

O principal dataset utilizado, intitulado [Full TMDb Movies Dataset 2024 \(1M Movies\)](#), é extenso e disponibiliza bastante informação financeira e de gênero e público dos títulos. Esses dados foram extraídos com a API TMDb pelo usuário asaniczka e são atualizados diariamente. Este dataset foi disponibilizado em acordo com a licença [ODC Attribution License \(ODC-By\)](#).

O segundo dataset, intitulado [TMDb 5000 Movie Dataset](#), foi atualizado pela última vez há nove anos e abarca apenas uma fração dos filmes do primeiro, mas mantém um arquivo com os créditos dos filmes que disponibiliza informações detalhadas sobre o elenco e equipe preservando inclusive seus ids pessoais, sendo assim particularmente interessante para responder perguntas relativas aos envolvidos nas produções. Este dataset foi disponibilizado em acordo com as [regras padrão do TMDb](#) e de [sua API](#).

As condições de ambos os datasets permitem a utilização e manipulação de seus dados para o uso previsto por este trabalho. Os dois disponibilizam seus arquivos no formato .csv, que foi baixado e posteriormente inserido na plataforma manualmente. O dataset TMDb 5000 Movie Dataset disponibiliza dois arquivos, mas apenas o arquivo de créditos foi utilizado para o projeto, uma vez que o arquivo de filmes seria apenas uma repetição do Full TMDb Movies Dataset.

### III. Modelagem

Ao estruturar a modelagem dos dados, fez-se bastante atenção às análises futuras previstas. O TMDb é um popular site de banco de dados de filmes e séries, editado pela comunidade. Além de sua API aberta, ele conta com bom apelo para comunidades de nicho

e conteúdos e avaliações de fãs, oferecendo maior apoio a mídias alternativas e internacionais que um site mais comercial com, por exemplo, o IMDb.

Em contrapartida, o sistema de notas e contagem de votos do TMDb é menos robusto, sendo mais focado em estatísticas variáveis como a popularidade momentânea de uma série. Isso significa que para uso neste projeto, faz-se necessário tratar atributos relativos a por exemplo votação com cuidado para corrigir esse viés.

Sendo assim, foram previstas diversas colunas extras, como uma média bayesiana ao estilo do algoritmo do IMDb e alguns campos auxiliares como lucro e ROI. Essas colunas extras foram criadas na camada gold, a fim de preservar a estrutura dos dados ao máximo ao longo da pipeline.


Para a estrutura geral, foi utilizado o Star Schema, com uma tabela fato para os filmes e suas principais características de lançamento relacionadas a título, lançamento e faturamento. Além disso, tomou-se a decisão de manter apenas a produtora principal do filme no modelo gold, colocando-a diretamente na fato, uma vez que não era uma informação de suma importância para as análises previstas.

Em relação a demais manipulações previstas, antes mesmo de iniciar a pipeline foi verificado que os campos gênero, elenco e equipe eram jsons múltiplos, que teriam que ser tratados com cuidado.

| genres                                                | cast                                                                                                   | crew |
|-------------------------------------------------------|--------------------------------------------------------------------------------------------------------|------|
| [{"id": 35, "name": "Comedy"}, {"id": 10749, "na...}] | [{"cast_id": 4, "character": "Am\u00e9lie Poul...", "credit_id": "52fe4225c3a36847f800778b", "de...}]  |      |
|                                                       | [{"cast_id": 10, "character": "Steven Mills", "...", "credit_id": "52fe44b99251416c7503ec53", "de...}] |      |
|                                                       | [{"cast_id": 1, "character": "Jimmy", "credit_...", "credit_id": "52fe44aa9251416c91018887", "de...}]  |      |
|                                                       | [{"cast_id": 1, "character": "Forrest Taft", "...", "credit_id": "52fe4513c3a36847f80baed9", "de...}]  |      |
|                                                       | [{"cast_id": 6, "character": "Percy 'Smudge' S...", "credit_id": "52fe4a28c3a36847f81bd967", "de...}]  |      |

Como todos esses têm importância elevada para a análise foram tratados primeiramente na silver, *casteando* o json em array para que pudesse ser limpo, mas ainda mantido em um linha e sem perder informações nesta etapa.

Os arquivos originais foram mantidos separados desde o upload na plataforma até a injeção no schema gold, sendo então utilizada uma junção de suas tabelas limpas ainda silver para facilitar a estruturação do código.



Na camada gold todos esses arrays foram decompostos como previsto em tabela **dim\_people** – que disponibiliza informações pessoais compiladas e deduplicadas dos indivíduos de elenco e equipe, que por vezes acumulam funções – e **dim\_genre** e conectadas à tabela fato pelas tabelas auxiliares para elementos múltiplos **bridge\_film\_genre**, **bridge\_film\_cast** e **bridge\_film\_crew**.

## IV. Carga (ETL)

Os dados foram estruturados em modelo medalhão dentro do databricks.



A estrutura base do catálogo [mvpDE]>schemas [raw>bronze>silver>gold] foi montada pela própria interface da plataforma.


```

mvpDE[test].ipynb ☆ Saving...
File Edit View Insert Runtime Tools Help
Commands + Code + Text Run all
[ ]
! kaggle datasets download asaniczka/tmdb-movies-dataset-2023-930k-movies
! unzip tmdb-movies-dataset-2023-930k-movies

! kaggle datasets download tmdb/tmdb-movie-metadata
! unzip tmdb-movie-metadata
  
```

Os arquivos .csv escolhidos foram baixados e deszipados pelo Google Colab e em seguida baixados e inseridos manualmente em um Volume [film\_data] dentro do schema raw, usado aqui apenas para organizar arquivos fora do formato de tabela.






```
# READ TMDB_movie_dataset_v11.csv file from [0]raw.film_data
film_raw = (
    spark.read
    .format("csv") # file is comma separated csv
    .option("header", "true") # 1st line of csv is header
    .option("inferSchema", "true") # infer column data types (w no instruction reads as string)
    .option("multiline", "true") # single cells can have line breaks (prevents breaking at '\n')
    .option("escape", "") # ignore double quotes in file columns' text (eg. a description)
    .load("/Volumes/mvpde/0_raw/film_data/TMDB_movie_dataset_v11.csv") # path to csv file
)

# INSERT metadata into films bronze table
from pyspark.sql.functions import current_timestamp, col
film_bronze = (
    film_raw
    .withColumn("_ingest", current_timestamp())
    .withColumn("_source", col("_metadata.file_path"))
)

# SAVE film_bronze as Delta table
(
    film_bronze
    .write
    .format("delta")
    .mode("append") # sub for ("overwrite") if rerunning notebook
    .saveAsTable("mvpde.1_bronze.film") # path to save
)

> See performance (1)
2 dataframes: film_bronze, film_raw
> film_bronze: pyspark.sql.connect.dataframe.DataFrame = [id: integer, title: string ... 24 more fields]
> film_raw: pyspark.sql.connect.dataframe.DataFrame = [id: integer, title: string ... 22 more fields]
```

A estruturação dos demais schemas foi realizada por meio de notebooks dedicados, utilizando pyspark para leitura, transformação e persistência das tabelas delta. As inserções de comentário e eventuais testes e consultas pontuais foram realizadas majoritariamente em SQL. Esses notebooks comentados e suas saídas podem ser consultados na pasta dedicada do projeto to github.



```
-- Note on Syntax: Schema names starting with numbers (like _1_bronze) require backticks (`_1_bronze`) in ANSI-SQL compliant engines such as Databricks Unity Catalog /
Spark SQL to avoid parsing errors.
-- Target Table: catalog = mvpde, schema = 1_bronze, table = film

-- Ingested Metadata Columns (Inherited from DB Dataset)
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN id COMMENT 'Unique identifier assigned by TMDB for the movie';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN title COMMENT 'The primary display title of the movie';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN vote_average COMMENT 'Average user rating on TMDB (scale 0.0 to 10.0)';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN vote_count COMMENT 'Total number of user votes submitted on TMDB';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN status COMMENT 'Release status (e.g., Released, In Production, Post Production, Cancelled)';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN release_date COMMENT 'Official release date of the movie (YYYY-MM-DD)';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN revenue COMMENT 'Total box office revenue worldwide in USD';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN runtime COMMENT 'Total running time of the movie in minutes';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN adult COMMENT 'Flag indicating if the movie is classified for adult/mature audiences';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN backdrop_path COMMENT 'Relative path URL to the high-resolution backdrop image on TMDB DB';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN budget COMMENT 'Estimated production budget of the movie in USD';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN homepage COMMENT 'URL link to the official homepage or external website of the movie';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN imdb_id COMMENT 'Unique external identifier for the title on IMDb (e.g., tt0111161)';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN original_language COMMENT 'ISO 639-1 language code representing the original spoken language';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN original_title COMMENT 'Title of the movie in its original release language';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN overview COMMENT 'Brief synopsis or plot description of the movie';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN popularity COMMENT 'TMDB internal popularity metric score';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN poster_path COMMENT 'Relative path URL to the main poster image on TMDB DB';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN tagline COMMENT 'Official marketing slogan or tagline for the movie';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN genres COMMENT 'Comma-separated string or raw JSON array of assigned genre names';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN production_companies COMMENT 'Comma-separated string or raw JSON array of production company names';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN production_countries COMMENT 'Comma-separated string or raw JSON array of production country codes/names';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN spoken_languages COMMENT 'Comma-separated string or raw JSON array of spoken languages';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN keywords COMMENT 'Comma-separated string or raw JSON array of descriptive keywords/tags';

-- Pipeline Metadata Audit Columns
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN _ingested_at COMMENT 'Timestamp when the Spark pipeline processed the batch';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN _source_file_path COMMENT 'Full cloud storage file path of the source ingested file';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN _source_file_size COMMENT 'Source file size of the movie ingested file';
ALTER TABLE mvpde._1_bronze.film ALTER COLUMN _source_file_modification_time COMMENT 'Last modification timestamp of the source ingested file';

> See performance (2)
```

Para a camada bronze os dados foram transformados em tabela de forma crua, sem forçar tipagem nem alterar ou manipular conteúdo. As funções utilizadas garantem que o .csv seja lido adequadamente, especialmente o dos filmes, que possui descrições longas, uso de

aspas duplas no texto etc. Os campos desta tabela delta foram portanto todos lidos como String para serem posteriormente *casteados* para os tipos próprios.

Catalog Explorer > mvpde > 1\_bronze >

**credit** Open in a dashboard Share Create

Overview Sample Data Details Permissions Policies History Lineage Insights Quality

**Description**

The table contains information about movies, including their titles, cast, and crew. It can be used for analysis related to movie data, such as exploring casting patterns and understanding crew involvement.

Filter columns... AI generate

| Column                         | Type       | Popular... | Comment | Tags | Column masking |
|--------------------------------|------------|------------|---------|------|----------------|
| movie_id                       | string     | ----       |         |      | >              |
| title                          | string     | ----       |         |      | >              |
| cast                           | string     | ----       |         |      | >              |
| crew                           | string     | ----       |         |      | >              |
| _ingested_at                   | timesta... | ----       |         |      | >              |
| _source_file_path              | string     | ----       |         |      | >              |
| _source_file_name              | string     | ----       |         |      | >              |
| _source_file_modification_time | timesta... | ----       |         |      | >              |

**About this table**

Owner: ravenfrey@gmail.com

Type: Managed

Data source: Delta

Na camada silver foram feitas esses ajustes de tipagem, bem como transformações de limpeza e lógica do negócio. Entradas de datas completamente fora do padrão (leia-se extremamente antigas, pré indústria, ou em um futuro distante) foram eliminadas e valores zerados e/ou duplicados foram tratados.

Catalog Explorer > mvpde > 2\_silver >

film

Open in a dashboard

Share

Create

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Description

Silver layer TMDb movies table containing cleaned, typed, and deduplicated movie metadata (1 row per movie entity). Transformed from mvpde.1\_bronze.film.

Filter columns...

| Column       | Type   | Popul... | Comment                                                     | Tags | Column masking |
|--------------|--------|----------|-------------------------------------------------------------|------|----------------|
| id           | bigint | ----     | Unique TMDb movie identifier (Primary Key, cast to BIGINT). |      |                |
| title        | string | ----     | Primary localized display title of the movie.               |      |                |
| vote_average | double | ----     | Average user rating score on a 0 to 10 scale.               |      |                |
| vote_count   | bigint | ----     | Total number of user ratings submitted on                   |      |                |

| Column                                      | Type      |
|---------------------------------------------|-----------|
| >                                           | array     |
| > production_companies: {"items": "string"} | array     |
| >                                           | array     |
| > production_countries: {"items": "string"} | array     |
| >                                           | array     |
| > spoken_languages: {"items": "string"}     | array     |
| >                                           | array     |
| > keywords: {"items": "string"}             | array     |
| _bronze_ingested_at                         | timest... |
| _source_file_name                           | string    |
| _silver_processed_at                        | timest... |

Na camada gold estabelecemos por fim a estrutura final do projeto, com as tabelas delta em arranjo Star, a fim de facilitar as consultas e análises.

Catalog

Serverless Starter Wareho... Serverless 2XS

Catalog

Type to search

My organization

workspace

system

mvpde

0\_raw

Volumes (1)

film\_data

1\_bronze

2\_silver

Tables (3)

credit

film

film\_combined

3\_gold

Tables (7)

bridge\_film\_cast

bridge\_film\_crew

bridge\_film\_genres

dim\_genres

dim\_people

fact\_film

vw\_film\_summary

default

information\_schema

Shares received

samples

Catalog

Suggested

Favorites

Recents


Filter

| Name               | Reason for suggestion     | Type    |
|--------------------|---------------------------|---------|
| fact_film          | You viewed • 3 hours ago  | Table   |
| mvpde.3_gold       |                           |         |
| film_combined      | You viewed • 3 hours ago  | Table   |
| mvpde.2_silver     |                           |         |
| bridge_film_genres | You viewed • 6 hours ago  | Table   |
| mvpde.3_gold       |                           |         |
| dim_genres         | You viewed • 6 hours ago  | Table   |
| mvpde.3_gold       |                           |         |
| film               | You viewed • 7 hours ago  | Table   |
| mvpde.1_bronze     |                           |         |
| film               | You viewed • 8 hours ago  | Table   |
| mvpde.2_silver     |                           |         |
| credit             | You viewed • 8 hours ago  | Table   |
| mvpde.2_silver     |                           |         |
| credit             | You viewed • 10 hours ago | Table   |
| mvpde.1_bronze     |                           |         |
| film_data          | You viewed • 11 hours ago | Volume  |
| mvpde.0_raw        |                           |         |
| 2_silver           | You viewed • 4 hours ago  | Schema  |
| mvpde              |                           |         |
| 3_gold             | You viewed • 4 hours ago  | Schema  |
| mvpde              |                           |         |
| mvpde              | You viewed • 11 hours ago | Catalog |
| 1_bronze           | You viewed • 12 hours ago | Schema  |
| mvpde              |                           |         |
| 0_raw              | You viewed • 15 hours ago | Schema  |
| mvpde              |                           |         |

## V. Análise

As análises foram em sua maioria feitas em um notebook separado, também disponível no github. Algumas iniciais foram realizadas em consultas sql, mas a maior parte foi feita em pyspark e algumas utilizaram matplotlib para aspectos que são mais claros graficamente. A maioria das perguntas para as quais não havia sido encontrado empecilho antes de definir a base da dados puderem ser respondidas e foi uma análise ampla de onde surgiram *insights* para diferentes áreas e temáticas para pesquisas mais aprofundadas.

### Consulta elenco de American Beauty



The screenshot shows a Databricks SQL interface. At the top, a query is executed, returning 10 rows. The query is as follows:

```
%sql
SELECT
  f.title,
  b.cast_order,
  p.person_name,
  b.character_name,
  p.gender
FROM mvpde.'3_gold'.fact_film f
INNER JOIN mvpde.'3_gold'.bridge_film_cast b
  ON f.id = b.movie_id
INNER JOIN mvpde.'3_gold'.dim_cast p
  ON b.person_id = p.person_id
WHERE f.id = 14
ORDER BY b.cast_order ASC;
```

Below the query, there is a link to "See performance (1)" and a "Checked for improvements" status. The results are displayed in a table with the following columns: title, cast\_order, person\_name, character\_name, and gender. The table contains 15 rows of data, all for the movie "American Beauty".

| title           | cast_order | person_name       | character_name      | gender |
|-----------------|------------|-------------------|---------------------|--------|
| American Beauty | 0          | Kevin Spacey      | Lester Burnham      | Male   |
| American Beauty | 1          | Annette Bening    | Carolyn Burnham     | Female |
| American Beauty | 2          | Thora Birch       | Jane Burnham        | Female |
| American Beauty | 3          | Wes Bentley       | Ricky Fitts         | Male   |
| American Beauty | 4          | Mena Suvari       | Angela Hayes        | Female |
| American Beauty | 5          | Chris Cooper      | Colonel Frank Fitts | Male   |
| American Beauty | 6          | Scott Bakula      | Jim Olmeyer         | Male   |
| American Beauty | 7          | Peter Gallagher   | Buddy Kane          | Male   |
| American Beauty | 8          | Allison Janney    | Barbara Fitts       | Female |
| American Beauty | 9          | Sam Robards       | Jim Berkley         | Male   |
| American Beauty | 10         | Barry Del Sherman | Brad Dupree         | Male   |
| American Beauty | 11         | John Cho          | Sale House Man #1   | Male   |
| American Beauty | 12         | Hal Fort Atkinson | Sale House Man #2   | Male   |
| American Beauty | 13         | Kent Faulcon      | Sale House Man #3   | Male   |
| American Beauty | 14         | Ara Celi          | Sale House Woman #1 | Female |

At the bottom of the table, it shows "40 rows" and "5.270s runtime". The interface is refreshed at 9/27/26, 11:06 AM (3m ago).

Apesar de não ser uma pergunta prevista originalmente acabei mantendo essa consulta porque me pareceu interessante que um filme associado com a exploração do feminino tenha um elenco principal (números mais baixos em cast\_order) com uma presença masculina razoável.

Esse elenco é bastante completo, citando diversos atores não creditados originalmente, o que me fez me perguntar também sobre a potencial limitação dos dados, visto que um conjunto de dados mantido por comunidade sempre tem riscos de focos limitados. Nesse sentido torna-se ainda mais difícil extrair informações quantitativas comparativas deste conjunto em relação ao número de membros do elenco, por exemplo.

## Preponderância por Gênero

```
> 2 dataframes: genre_counts, genre_percentage_df
```

| genre_name      | movie_count | total_movies | percentage |
|-----------------|-------------|--------------|------------|
| Drama           | 248011      | 1148611      | 21.59      |
| Documentary     | 188617      | 1148611      | 16.42      |
| Comedy          | 151464      | 1148611      | 13.19      |
| Animation       | 64445       | 1148611      | 5.61       |
| Horror          | 58246       | 1148611      | 5.07       |
| Romance         | 57637       | 1148611      | 5.02       |
| Music           | 55032       | 1148611      | 4.79       |
| Thriller        | 49714       | 1148611      | 4.33       |
| Action          | 47930       | 1148611      | 4.17       |
| Crime           | 36039       | 1148611      | 3.14       |
| Family          | 29998       | 1148611      | 2.61       |
| Adventure       | 25749       | 1148611      | 2.24       |
| TV Movie        | 25716       | 1148611      | 2.24       |
| Fantasy         | 25767       | 1148611      | 2.24       |
| Science Fiction | 23237       | 1148611      | 2.02       |
| Mystery         | 22547       | 1148611      | 1.96       |
| History         | 17988       | 1148611      | 1.57       |

A maior parte dos gêneros dessa lista são bastante previsíveis em questão de serem gêneros tidos como populares e que portanto seriam bastante produzidos. Como Drama, Comédia e Romance por exemplo são bem comuns como dentro do conjunto de gêneros é possível que a posição tenha sido um pouco inflada.

É um pouco surpreendente que Documentário esteja em uma posição proporcional tão alta, principalmente porque diversos outros gêneros que o acompanham não são muito preponderantes, mas bem interessante.

## Lucro por Gênero

```
> 2 dataframes: genre_market_share, genre_revenue_df
```

| genre_name      | total_genre_revenue | total_industry_revenue | market_share_pct |
|-----------------|---------------------|------------------------|------------------|
| Action          | 185219303752        | 797301153731           | 23.23            |
| Comedy          | 111642925896        | 797301153731           | 14.0             |
| Drama           | 108976589578        | 797301153731           | 13.67            |
| Adventure       | 105313352826        | 797301153731           | 13.21            |
| Animation       | 60027864632         | 797301153731           | 7.53             |
| Horror          | 37515442644         | 797301153731           | 4.71             |
| Science Fiction | 33889906624         | 797301153731           | 4.25             |
| Fantasy         | 30783854091         | 797301153731           | 3.86             |
| Family          | 28912419238         | 797301153731           | 3.63             |
| Thriller        | 23376603780         | 797301153731           | 2.93             |
| Crime           | 19575683404         | 797301153731           | 2.46             |
| Romance         | 13765202239         | 797301153731           | 1.73             |
| Music           | 11812334016         | 797301153731           | 1.48             |
| Mystery         | 9363213977          | 797301153731           | 1.17             |
| War             | 6939954515          | 797301153731           | 0.87             |


only showing top 15 rows

Nesta análise já é mais visível a influência de múltiplos gêneros e as razões da popularidade de alguns. Mais interessante é perceber ao comparar com a tabela anterior a diversidade de gêneros que são produzidos por razões que não diretamente ou não majoritariamente visam o lucro.

## Lucro e ROI por Era do Cinema


> 2 dataframes: era\_financial\_summary, pdf

| film_era                      | movie_count | total_budget | total_revenue | total_profit | avg_movie_roi | portfolio_roi |
|-------------------------------|-------------|--------------|---------------|--------------|---------------|---------------|
| Digital & Franchise Era       | 7112        | 170924418144 | 497316975202  | 326392557058 | 719069.56     | 2.91          |
| Blockbuster Era               | 2486        | 46109432721  | 125488808726  | 79379376005  | 1307.13       | 2.72          |
| Streaming & Post-Pandemic Era | 3625        | 33207633617  | 109669887814  | 76462254197  | 594473.7      | 3.3           |
| New Hollywood                 | 390         | 2329231568   | 14727326620   | 12398095052  | 33.63         | 6.32          |
| Golden Age of Hollywood       | 764         | 1692223162   | 8551749053    | 6859525891   | 7.78          | 5.05          |
| Silent Era                    | 145         | 33922130     | 110362406     | 76440276     | 16.85         | 3.25          |




Essa foi uma descoberta super interessante, pois apesar da valorização do dinheiro não esperava uma diferença tão grande. É particularmente bom ter incluído o ROI também porque se pode ver que apesar dos gastos maiores isso não se traduz é um lucro que acompanhe. Poderia ser interessante comparar aqui com outras indústrias que também fossem ativas nessas Eras.

Filmes mais populares Receita x Orçamento



Filmes mais e menos lucrativos



Aqui percebe-se que há uma alta popularidade de heróis da Marvel, apesar de talvez essa ser uma tendência já um pouco datada. Chamam atenção em particular um título como Titanic se mantendo e também nos em maiores dificuldades que há filmes bem vistos como The Bear e Gray Man que por outros motivos às vezes como produção independente ou streamings que não baseiam seu modelo de negócio em lucro direto aparecem em um conjunto desse tipo.

### Figuras mais prolíficas da indústria (atores)

```
=== TOP 5 MOST PROLIFIC ACTORS ===
```

| person_id | person_name       | movie_count | avg_movie_rating |
|-----------|-------------------|-------------|------------------|
| 2231      | Samuel L. Jackson | 67          | 6.6              |
| 380       | Robert De Niro    | 57          | 6.61             |
| 62        | Bruce Willis      | 51          | 6.44             |
| 1892      | Matt Damon        | 48          | 6.8              |
| 192       | Morgan Freeman    | 46          | 6.76             |

Na tabela dos atores é interessante que comparado a outros profissionais do cinema são mais de duas vezes mais prolíficos. Me pergunto se é apenas uma questão de tempo ou se envolve questões mais emocionais ou de pressões externas.

### Figuras mais prolíficas da indústria (diretores)

```
=== TOP 5 MOST PROLIFIC DIRECTORS ===
```

| person_id | person_name      | movie_count | avg_movie_rating |
|-----------|------------------|-------------|------------------|
| 488       | Steven Spielberg | 27          | 7.2              |
| 1243      | Woody Allen      | 22          | 6.69             |
| 1032      | Martin Scorsese  | 21          | 7.35             |
| 190       | Clint Eastwood   | 20          | 7.03             |
| 2294      | Robert Rodriguez | 17          | 6.11             |

Quanto à tabela dos diretores, é impressionante que mesmo nesses números elevados vários tenham mantido a sua média de nota mais elevada em comparação. Suponho que até um certo ponto seja também pelo maior poder que têm em relação ao produto final e uma maior associação direta entre obra e reputação.

### Figuras mais prolíficas da indústria (escritores)

```
=== TOP 5 MOST PROLIFIC WRITERS ===
```

| person_id | person_name     | movie_count | avg_movie_rating |
|-----------|-----------------|-------------|------------------|
| 9856      | Ian Fleming     | 24          | 6.59             |
| 1243      | Woody Allen     | 22          | 6.72             |
| 59        | Luc Besson      | 21          | 6.42             |
| 3027      | Stephen King    | 18          | 6.8              |
| 4723      | Brian Koppelman | 17          | 6.62             |

Interessante aqui que tantos sejam escritores de livros. Em parte isso se deve claro ao fato de serem famosos em outro meio e portanto tem créditos em suas obras mesmo que não tenham escrito o roteiro do filme. As notas mais baixas que diretores são interessantes talvez como reflexão do que é mais valioso em cada contexto.

## Importância dos filmes de Animação, progressão ao longo dos anos

|    | Table                 | +                        |
|----|-----------------------|--------------------------|
|    | 1 <sup>o</sup> decade | 1 <sup>o</sup> num_films |
| 1  | 1890                  | 10                       |
| 2  | 1900                  | 48                       |
| 3  | 1910                  | 332                      |
| 4  | 1920                  | 1339                     |
| 5  | 1930                  | 2255                     |
| 6  | 1940                  | 1972                     |
| 7  | 1950                  | 2099                     |
| 8  | 1960                  | 2618                     |
| 9  | 1970                  | 3365                     |
| 10 | 1980                  | 4559                     |
| 11 | 1990                  | 5078                     |
| 12 | 2000                  | 8023                     |
| 13 | 2010                  | 15919                    |
| 14 | 2020                  | 16828                    |

14 rows 3.782s runtime

Extremamente interessante como o crescimento desse setor se deu de forma rápida no início, com progressão quase exponencial e eventualmente atingiu um *plateau* por volta da era Disney e de desenhos animados para depois voltar a crescer mais moderadamente. Seria interessante comparar esses números com os de desenhos animados para TV e observar se há algum tipo de correlação.

De uma forma geral vejo a análise como esclarecedora e positiva. Gostaria de dados mais extensos e específicos sobre certos aspectos, tanto sobre equipe que esperava ter encontrado mais detalhes, quanto sobre aspectos mais técnicos de um filme como os color guides e curvas de ação. Já vi alguns projetos mais gráficos envolvendo reconhecimento de filme pela paleta de cor de suas cenas, mas sempre apresentado como uma diversão, nunca como algo mais analítico. Com certeza em grande parte devido a limitações técnicas, mas aos poucos me parece mais próximo de nossa realidade.

## VI. Autoavaliação

Esta foi uma experiência bastante positiva no contexto de aprender algo completamente novo. Muito do que eu imaginava é completamente diferente e os desafios vieram de locais inesperados. A organização em tabelas ao mesmo tempo que facilita muitas coisas do processo de inserção e reingestão de dados tolhe um pouco a visão inicial e análise menos direcionada. Levei um tempo para me acostumar.

Como sou uma pessoa bastante curiosa – vide todas as perguntas não respondidas e criadas aos poucos a partir de outras – não poderia me dizer completamente satisfeita, mas do ponto de vista de estudo e profissão diria que foi uma excelente introdução, que me deu vontade de ir além, encontrar dados de outros tipos, evoluir cada vez mais.

Em relação ao projeto em si achei os *insights* interessantes e os dados disponíveis mais detalhados do que imaginava. Acredito ter cumprido todos os objetivos do MVP e honestamente me sinto um pouco triste de não ser uma experiência mais longa ou com algumas etapas guiadas.